Universidade Federal da Paraíba Centro de Informática Departamento de Informática	Aprendizado Profundo Perióodo 2026.2 Professor: Tiago Maritan

LISTA DE EXERCÍCIOS
Data de Entrega: 17/11/2026

ORIENTAÇÕES:

- **A lista pode ser resolvida em grupo de até 3 integrantes.**
- **No dia da entrega da lista de exercícios, o(s) grupo(s) deverão(m) fazer uma apresentação para a turma de cerca de 10 a 15 min, e enviar um link com a sua resolução da lista (contendo códigos-fontes, resultados, etc) no formulário de envio de atividades próprio disponibilizado pelo professor no SIGAA.**

1) Implemente uma Rede Perceptron de Múltiplas Camadas (MLP) para resolver os problemas a seguir.

a) Utilize a Rede neural para aproximar a função a seguir:

$$f(x) = 3\sin(2x) + 2\cos(5x) + 0,5x^2, \text{ onde } 0 \leq x \leq 10.$$

Para aproximar essa função:

- gere conjuntos de treinamento e teste;
- utilize (x) como entrada e (f(x)) como saída desejada;
- treine a rede neural utilizando apenas o conjunto de treinamento;
- avalie o desempenho da rede durante o treinamento utilizando o conjunto de teste.

Apresente as seguintes informações:

- gráfico da função real e da função aproximada;
- curva de erro de treinamento;
- curva de erro de validação;
- métricas MAE, MSE e RMSE;
- gráfico comparando as curvas real e predita.

b) Utilize a base de dados **Diabetes Dataset**, disponível na biblioteca Scikit-Learn (https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_diabetes.html), e utilize a Rede (MLP) para prever uma medida quantitativa de progressão da doença a partir dos atributos disponíveis. O dataset possui 442 amostras, contendo 10 variáveis preditoras e um alvo quantitativo que representa a progressão da doença um ano após a medição inicial.

Apresente:

- análise exploratória dos dados;
- tratamento e normalização dos atributos (se aplicável);
- arquitetura da rede utilizada;
- curvas de treinamento e validação;
- métricas MAE, MSE e RMSE;
- gráfico comparando valores reais e preditos.

2) Implemente uma Rede Perceptron de Múltiplas Camadas (MLP) para resolver um problema de classificação utilizando a base Wine Quality Dataset (UCI), disponível em https://archive.ics.uci.edu/dataset/186/wine+quality.

O objetivo é prever a qualidade de vinhos a partir de suas características físico-químicas, como acidez, teor alcoólico, pH, densidade e demais atributos disponíveis.

Para este exercício, transforme a variável de qualidade em três categorias:

- Qualidade baixa: notas de 0 a 4;
- Qualidade média: notas 5 e 6;
- Qualidade alta: notas de 7 a 10.

Realize uma análise exploratória e o pré-processamento dos dados, contemplando valores ausentes, atributos redundantes, normalização e distribuição das classes. Avalie a necessidade de técnicas de balanceamento.

Após o treinamento, apresente:

- arquitetura da rede utilizada;
- curvas de erro de treinamento e validação;
- matriz de confusão;
- métricas accuracy, precision, recall e f1-score.

3) Neste exercício, utilize a base CIFAR-10, disponível em: https://cave.cs.toronto.edu/kriz/cifar.html, e implemente dois classificadores distintos:

a) uma Rede Perceptron de Múltiplas Camadas (MLP);
b) uma Rede Neural Convolucional (CNN).

Para ambos os modelos, apresente:

- arquitetura utilizada;
- curvas de erro de treinamento e validação;
- matriz de confusão;
- acurácia final no conjunto de teste.

4) Utilize a CNN desenvolvida na Questão 3 e investigue as representações aprendidas pela rede ao longo do treinamento.

a) Extraia e visualize os filtros aprendidos pela primeira camada convolucional da rede, apresentando uma visualização dos filtros aprendidos, e se possível, faça uma descrição qualitativa dos padrões observados;

b) Selecione pelo menos 5 imagens do conjunto de teste e visualize os mapas de ativação produzidos por uma camada convolucional intermediária da rede.

Apresente:

- imagem original;
- mapas de ativação gerados pela rede;
- análise qualitativa das regiões da imagem que mais contribuíram para a ativação dos neurônios.

c) Selecione exemplos corretamente classificados e exemplos classificados incorretamente pela CNN. Para cada caso, apresente a imagem original, a classe verdadeira, a classe predita e a probabilidade associada à predição (ou score equivalente).

5) Utilize o dataset Fashion-MNIST, disponível em https://www.kaggle.com/datasets/zalando-research/fashionmnist, para realizar as atividades descritas a seguir.

a) Implemente e treine um autoencoder capaz de reconstruir as imagens do conjunto de dados. O modelo pode ser construído utilizando apenas camadas densas (*fully connected*), ou camadas convolucionais e deconvolucionais.

Treine pelo menos **três versões do modelo** utilizando diferentes tamanhos para o espaço latente (ex: vetor latente com 100, 50 e 30 componentes).

Após o treinamento, apresente:

- arquitetura utilizada;
- selecione 10 imagens do conjunto de teste e compare os erros de reconstrução e qualidade das imagens reconstruídas;
- apresente visualmente as imagens originais e reconstruídas.

b) Adicione ruído aleatório às imagens de entrada e treine um novo autoencoder com o objetivo de remover esse ruído. Após o treinamento, utilize as mesmas 10 imagens selecionadas anteriormente e apresente as imagens ruidosas e as reconstruções produzidas pelo modelo.

Bom trabalho!!!!